

Media y Mediana

Estadística Descriptiva

Ain Bolaños Cortés
Universidad Panamericana
0267980@up.edu.mx

Contenido

1. Medidas de tendencia central	3
2. Media	3
2.1. Definición	3
2.2. Propiedades Matemáticas	3
2.3. Implementación	3
3. Mediana	5
3.1. Definición	5
3.2. Propiedades Matemáticas	5
3.3. Implementación	5
4. Asimetría	7
5. Bibliografía	8

1. Medidas de tendencia central

También conocidas como medidas muestrales de tendencia central, debido a que parten de una muestra aleatoria $\underline{X} = \{X_1, X_2, \dots, X_n\}$, son estadísticas que buscan analizar de forma colectiva los datos obtenidos. Esto es, más allá de la representación visual, estas estadísticas son valores objetivos sobre la naturaleza de la distribución de nuestra muestra.

Con todo lo anterior, en la estadística descriptiva, las dos medidas de tendencia central más utilizadas son claramente la **media** y la **mediana**, y resultan protagónicas para un primer estudio de las muestras aleatorias.

2. Media

2.1. Definición

¶ **Def. 2.1** (*Media*)

Dado un conjunto de n observaciones, $x_1, x_2, \dots, x_n$, la **media** es la suma de estas observaciones dividida entre n , y se denota como $\bar{x}$. Es decir:

$$\bar{x} = \frac{\sum_{i=1}^n x_i}{n}$$

Podemos ver la media como el punto de concentración de los datos, o el “centro de masa” de los mismos. Por ejemplo, la altura promedio en metros de la generación δ (nosotros).

2.2. Propiedades Matemáticas

Podemos intuitivamente entender el caso en que $n \rightarrow \infty$, bajo ciertas condiciones de representatividad, se tiene que $\bar{x} \rightarrow E[X_i]$ para cualquier i en la muestra, esto deriva de la *ley de los grandes números*. Esto significa que la media muestral es un estimador consistente de la esperanza poblacional.

- **Suma de desviaciones nula:**

La suma de las desviaciones de cada observación respecto de la media es cero:

$$\sum_{i=1}^n (x_i - \bar{x}) = 0$$

¶ **Prueba. 2.1**

$$\sum_{i=1}^n (x_i - \bar{x}) = \sum_{i=1}^n x_i - n\bar{x} = n\bar{x} - n\bar{x} = 0$$

■

- **Sensibilidad a valores atípicos (outliers):**

La media es extremadamente sensible a valores extremos. Por ejemplo, en el conjunto de datos $\{4, 5, 6, 7, 100\}$, la media es 24.4, mientras que la mayoría de los datos están alrededor de 5 o 6. *Un solo valor atípico puede distorsionar por completo la media.*

2.3. Implementación

2.3.1. Ejemplo a Mano

Consideremos las alturas (en metros) de la generación δ :

- Mariana = 1.50
- Mateo = 1.60
- Viken = 1.67
- Ain = 1.67
- Alen = 1.74
- Rodrigo = 1.70
- Leyre = 1.63
- Natalia = 1.63
- Diego = 1.70

Suma total: $1.50 + 1.60 + 1.67 + 1.67 + 1.74 + 1.70 + 1.63 + 1.63 + 1.70 = 14.84$

Media: $\bar{x} = \frac{14.84}{9} \approx 1.6489$ metros.

2.3.2. Media en Python

Puedes usar `numpy` para calcular la media sobre un arreglo (`np.array`). Replicando el ejemplo a mano:

🔗 Código. 2.1

```
import numpy as np

# Datos de alturas
alturas = np.array([1.50, 1.60, 1.67, 1.67, 1.74, 1.70, 1.63, 1.63, 1.70])
media = np.mean(alturas)
print(f"Media calculada con Python: {media:.4f} m")
```

• Output:

```
$ python3 main.py
> "Media calculada con Python: 1.6489 m"
```

2.3.3. Media en R

En **R** se puede usar `mean` sobre el vector de un `DataFrame`:

🔗 Código. 2.2

```
# Datos de alturas
alturas <- c(1.50, 1.60, 1.67, 1.67, 1.74, 1.70, 1.63, 1.63, 1.70)
media <- mean(alturas)
cat("Media calculada con R:", round(media, 4), "m\n")
```

• Output:

```
> "Media calculada con R: 1.6489 m"
```

3. Mediana

3.1. Definición

 **Def. 3.1** (*Mediana*)

Dado un conjunto de n observaciones $x_1, x_2, \dots, x_n$, la **mediana** es el valor m_c definido en los siguientes dos casos:

1. Con **n impar**, entonces m_c es el valor que ocupa la posición $\frac{n+1}{2}$ una vez que los datos han sido ordenados, es decir,

$$m_c = x_{(\frac{n+1}{2})}$$

2. Si **n es par**, definimos a la mediana como la media aritmética de los dos valores centrales, en las posiciones $\frac{n}{2}$ y $\frac{n}{2} + 1$ de los valores ordenados, es decir,

$$m_c = \frac{x_{(\frac{n}{2})} + x_{(\frac{n}{2}+1)}}{2}$$

3.2. Propiedades Matemáticas

La mediana en terminos prácticos divide tu muestra de acuerdo a su aparición exáctamente a la mitad, es decir, es la frontera entre el 50% superior y el 50% inferior de los datos.

- **Robusta:** Y se dice que es **robusta** debido a que no se ve afectada por valores atípicos. Siguiendo el ejemplo pasado con $\{4, 5, 6, 7, 100\}$, la mediana será 6, que representa mucho mejor a la muestra que el pasado 24.4. En distribuciones asimétricas o con outliers se tiende a tomar la mediana como el “valor típico”.

3.3. Implementación

3.3.1. Ejemplo a Mano

Utilizando los mismos 9 datos de las alturas de la generación δ hacemos lo siguiente sobre los datos ordenados:

$$\{1.50, 1.60, 1.63, 1.63, 1.67, 1.67, 1.70, 1.70, 1.74\}$$

1. Notamos que $n = 9$ es impar, entonces, nos podemos tomar el valor en la posición central:

$$\frac{9+1}{2} = 5 \Rightarrow m_c = 1.67$$

2. Digamos que al conjunto le agregamos el dato de Valeria, con altura de 1.78, entonces, tendríamos un nuevo $n = 10$. Con lo que el conjunto queda de la siguiente manera:

$$\{1.50, 1.60, 1.63, 1.63, 1.67, 1.67, 1.70, 1.70, 1.74, 1.78\}$$

Con lo que entonces, existen dos valores medios $\frac{10}{2} = 5$, y $\frac{10}{2} + 1 = 6$ con lo que

$$m_c = \frac{1.67 + 1.67}{2} = 1.67$$

3.3.2. Mediana en Python

Así como existe `mean` en `numpy` se puede usar `median()` sobre un arreglo.

¶ Código. 3.1

```
import numpy as np

alturas_par = np.array([1.50, 1.60, 1.63, 1.63, 1.67, 1.67, 1.70, 1.70, 1.74, 1.78])
mediana = np.median(alturas_par)
print(f"Mediana calculada con Python: {mediana:.4f} m")
```

- Output:

```
$ python3 main.py
> "Media calculada con Python: 1.6700 m"
```

3.3.3. Mediana en R

En **R** podemos usar la función `median` así como en Python.

¶ Código. 3.2

```
alturas_par <- c(1.50, 1.60, 1.63, 1.63, 1.67, 1.67, 1.70, 1.70, 1.74, 1.78)
mediana <- median(alturas_par)
cat("Mediana calculada con R:", round(mediana, 4), "m\n")
```

- Output:

```
$ python3 main.py
> "Media calculada con R: 1.6700 m"
```

4. Asimetría

También conocida como **Skewness**, es la relación entre la media y la mediana, y nos indica como se distribuyen los datos.

1. Si $\bar{x} \approx m_c$, entonces la distribución es **simétrica**.
2. Si $\bar{x} > m_c$, entonces la distribución tiene un **sesgo positivo**, es decir tiene una *cola derecha*.
3. Si $\bar{x} < m_c$, entonces la distribución tiene un **sesgo negativo**, es decir tiene una *cola izquierda*.

En los ejemplo final con las alturas de δ y Valeria, teníamos los siguientes datos:

$$\bar{x} = 1.6489, \text{ y } m_c = 1.67$$

Con lo que podemos pues ver que existe un muy ligero *sesgo negativo*.

El uso de la asimetría y el entendimiento de los sesgos existentes resulta fundamental para decidir que medida de tendencia central se utilizará en el análisis de los datos.

5. Bibliografía

- Walpole, R. E., Myers, R. H., Myers, S. L., & Ye, K. (2012). Probabilidad y estadística para ingeniería y ciencias (9.^a ed.). Pearson.
- Vázquez Alamilla, J., Naranjo Albarrán, L., Fuentes García, R., & Chávez Cano, M. (2019). Inferencia estadística para estudiantes de ciencias (1.^a ed.). Universidad Nacional Autónoma de México, Facultad de Ciencias.